영화 대사 코퍼스 기반 텍스트 분류 모델 성능 비교 및 분석

Nov 2, 2026 · @Nicole · CANLAS NICOLE (2555039)

1. 데이터 및 실험 설정

제공 CSV는 DARTH VADER 대사가 0행이고(Cornell 표기명은 `VADER`), 다른 영화의 동명 캐릭터 대사(『Dune』의 EMPEROR 등)가 섞여 있으며, "1000lines" 파일은 실제 552행이었다. 따라서 Cornell 원본에서 스타워즈 3부작(영화 ID 필터)만 재추출하고, 중복·라벨 충돌 대사를 제거한 데이터를 주 실험에 사용했다. 4개 캐릭터의 스타워즈 대사는 원본에 약 490행뿐이라 1,000행 구성은 불가능했다.

데이터셋	LUKE	LEIA	VADER	EMPEROR	합계	Bad 비율
Small (Part 1)	94	–	25	6	125	24.8%
Large (Part 2)	229	175	62	14	480	15.8%
제공 Large (비교용)	340	174	0	23	537	4.3%

평가는 모든 설정이 공유하는 반복 층화 5-Fold(25개 폴드)이며, 벡터라이저와 분류기를 Pipeline으로 묶어 훈련 폴드에서만 학습했다.

2. 통합 결과표

25개 폴드 평균이며 Macro-F1은 ± 표준편차다.

데이터	벡터화	모델	불균형	Acc	Bad P	Bad R	Bad F1	Macro-F1
Small	TF-IDF	LogReg	balanced	0.813	0.660	0.567	0.593	0.735 ± 0.107
Small	SBERT	LogReg	balanced	0.858	0.735	0.708	0.710	0.807 ± 0.088
Large	TF-IDF	LinearSVC	balanced	0.890	0.716	0.537	0.605	0.771 ± 0.035
Large	TF-IDF	LogReg	balanced	0.876	0.622	0.587	0.599	0.763 ± 0.040
Large	SBERT	LogReg	balanced	0.847	0.522	0.722	0.599	0.752 ± 0.046
Large	Count	MultinomialNB	none	0.896	0.826	0.437	0.560	0.751 ± 0.070
Large	Count	GradBoost	balanced	0.856	0.588	0.507	0.528	0.721 ± 0.064
Large	Count	RandomForest	none	0.870	0.888	0.198	0.315	0.622 ± 0.074

3. 연구 질문 답변 및 최종 모델

Q1. 데이터 규모: 20개 설정 중 19개에서 Macro-F1이 오르고 19개에서 표준편차가 줄었다(최종 모델 0.107 → 0.040). 다만 Bad Recall은 0.567 → 0.587로 거의 같았다.

Q2. Accuracy vs Bad Recall: Large에서 Accuracy 1위는 Count + NB(0.896)지만 Bad Recall은 0.437이다. balanced 미적용 TF-IDF LR은 Accuracy 0.842로 보이지만 거의 전부 Good으로 예측했고(Bad Recall 0.003), 제공 Large에서는 Bad를 하나도 못 찾은 RF가 Accuracy 0.957을 기록했다.

Q3. Count vs TF-IDF: 선형 모델(balanced)에서는 TF-IDF가 Macro-F1을 0.03–0.05 높였고, NB·RF에서는 Count가 나았다. 대사 중앙값이 6단어라 빈도가 대부분 0/1이어서, IDF보다 L2 정규화에 따른 특징값 축소의 영향이 컸던 것으로 보인다.

Q4. 가장 균형 잡힌 모델 (최종 선정): TF-IDF + 로지스틱 회귀(balanced)다. Small 1위(0.735)·Large 2위(0.763)로 두 규모 모두 상위이고, Large 1위 LinearSVC(0.771)와 함께 Bad Precision·Recall이 모두 0.5 이상이다. RF는 모든 조건에서 Bad Recall 0.20 이하였다.

Q5. 사전학습 임베딩: SBERT(all-MiniLM-L6-v2) + LR(balanced)은 Small에서 Macro-F1 0.807로 TF-IDF(0.735)보다 0.07 높았다. Large에서는 Bad Recall이 높았지만(0.722 vs 0.587) Precision이 낮아(0.522) Macro-F1은 비슷했다(0.752). 인코딩은 CPU에서 문장당 약 12 ms로 저렴해, 소규모 데이터나 Bad 재현율이 중요할 때 쓸 가치가 있다.

4. 오분류 사례 분석

최종 모델(Large)은 Bad 76개 중 33개를 놓치고 Good 24개를 Bad로 오판했다. 화자 성향보다 주제어와 명령조 문체(관사 "the")를 학습한 탓이다.

실제 → 예측	화자: 대사	원인 (기여 단어)
Bad → Good	VADER: What is thy bidding, My Master?	what(+0.28)이 my master(−0.41) 상쇄
Good → Bad	LUKE: Lord Vader … Is the dark side stronger?	악역 주제어 dark side(−0.23)
Good → Bad	LEIA: Yes.	Vader 대사 탓에 yes(−0.74)

5. 한계 및 개선 방안

- **한계:** Bad가 76개(폴드당 약 15개)뿐이라 Bad 지표 표준편차가 0.06–0.10으로 커서 상위 모델 간 차이를 구분할 수 없다. 캐릭터 기반 라벨이라 "Yes." 같은 대사는 원리적으로 분류할 수 없고, Large는 표본 수와 LEIA 추가가 함께 바뀌어 규모 효과가 분리되지 않았다.
- **개선:** 중첩 교차검증으로 하이퍼파라미터·임계값 조정, 악역 캐릭터와 LLM 비교 추가.