영화 대사 코퍼스 기반 텍스트 분류 모델 성능 비교 및 분석

Nov 2, 2026 · @Nicole · CANLAS NICOLE (2555039)

1. 데이터 준비

실험을 시작하기 전에 제공된 CSV 파일을 직접 확인해 보니 계획서와 다른 점이 세 가지 있었습니다. DARTH VADER 대사가 0행이었고(Cornell 코퍼스에는 `VADER`로 표기됨), 다른 영화의 같은 이름 캐릭터 대사(『Dune』의 EMPEROR 등)가 섞여 있었으며, "1000lines" 파일은 실제로 552행이었습니다. 그래서 저는 Cornell 원본에서 영화 ID로 스타워즈 3부작만 다시 추출하고 중복·라벨 충돌 대사를 제거했습니다. 네 캐릭터의 스타워즈 대사가 약 490행뿐이라 1,000행은 만들 수 없었습니다.

데이터셋	LUKE	LEIA	VADER	EMPEROR	합계	Bad 비율
Small (Part 1)	94	–	25	6	125	24.8%
Large (Part 2)	229	175	62	14	480	15.8%
제공 Large (비교용)	340	174	0	23	537	4.3%

모든 실험은 같은 반복 층화 5-Fold(25개 폴드)로 평가했고, 데이터 누출을 막기 위해 벡터라이저와 분류기를 Pipeline으로 묶었습니다.

2. 결과표

25개 폴드 평균이며, Macro-F1은 평균 ± 표준편차입니다.

데이터	벡터화	모델	불균형	Acc	Bad P	Bad R	Bad F1	Macro-F1
Small	TF-IDF	LogReg	balanced	0.813	0.660	0.567	0.593	0.735 ± 0.107
Small	SBERT	LogReg	balanced	0.858	0.735	0.708	0.710	0.807 ± 0.088
Large	TF-IDF	LinearSVC	balanced	0.890	0.716	0.537	0.605	0.771 ± 0.035
Large	TF-IDF	LogReg	balanced	0.876	0.622	0.587	0.599	0.763 ± 0.040
Large	SBERT	LogReg	balanced	0.847	0.522	0.722	0.599	0.752 ± 0.046
Large	Count	MultinomialNB	none	0.896	0.826	0.437	0.560	0.751 ± 0.070
Large	Count	GradBoost	balanced	0.856	0.588	0.507	0.528	0.721 ± 0.064
Large	Count	RandomForest	none	0.870	0.888	0.198	0.315	0.622 ± 0.074

3. 연구 질문에 대한 답

Q1. 데이터 규모: 데이터를 늘리니 20개 설정 중 19개에서 Macro-F1이 오르고 19개에서 표준편차가 줄었습니다(최종 모델 0.107 → 0.040). 하지만 Bad Recall은 0.567 → 0.587로 거의 그대로였습니다.

Q2. Accuracy vs Bad Recall: Large에서 Accuracy가 가장 높은 Count + NB(0.896)는 Bad Recall이 0.437에 그쳤습니다. 가중치 없는 TF-IDF LR은 Accuracy 0.842였지만 거의 모든 대사를 Good으로 예측했습니다(Bad Recall 0.003). 불균형 데이터에서는 Accuracy만 보면 안 된다는 것을 직접 확인했습니다.

Q3. Count vs TF-IDF: 선형 모델(balanced)에서는 TF-IDF가 Macro-F1을 0.03–0.05 높였고, NB·RF에서는 Count가 더 좋았습니다. 대사가 짧아(중앙값 6단어) 단어 빈도가 대부분 0 또는 1이라서, IDF보다 L2 정규화의 영향이 컸다고 생각합니다.

Q4. 최종 모델: 저는 TF-IDF + 로지스틱 회귀(balanced)를 선택했습니다. Small 1위(0.735), Large 2위(0.763)로 두 규모에서 모두 상위였고 Bad Precision·Recall이 모두 0.5 이상이었습니다.

Q5. 사전학습 임베딩: SBERT(all-MiniLM-L6-v2) + LR(balanced)을 Colab에서 같은 폴드로 실행했습니다. Small에서는 Macro-F1 0.807로 TF-IDF(0.735)보다 높았고, Large에서는 Bad Recall은 높았지만(0.722 vs 0.587) Precision이 낮아(0.522) Macro-F1이 비슷했습니다(0.752). 인코딩이 문장당 약 12 ms로 빨라서, 데이터가 적을 때는 쓸 가치가 있다고 판단했습니다.

4. 오분류 사례

최종 모델(Large)은 Bad 76개 중 33개를 놓쳤고 Good 24개를 Bad로 잘못 분류했습니다. 화자의 성격보다 주제어와 명령조 문체(관사 "the")를 학습한 것으로 보입니다.

실제 → 예측	화자: 대사	원인 (기여 단어)
Bad → Good	VADER: What is thy bidding, My Master?	what(+0.28)이 my master(−0.41) 상쇄
Good → Bad	LUKE: Lord Vader … Is the dark side stronger?	악역 주제어 dark side(−0.23)
Good → Bad	LEIA: Yes.	Vader 대사 탓에 yes(−0.74)

5. 한계와 배운 점

- **한계와 개선:** Bad가 76개뿐이라 상위 모델 간 차이를 구분하기 어렵고, "Yes." 같은 대사는 캐릭터 라벨로는 분류할 수 없습니다. 다음에는 중첩 교차검증과 악역 캐릭터 추가로 보완하고 싶습니다.
- **배운 점:** 유학생으로서 한국어 수업 자료와 영어 데이터를 함께 다루며, 모델보다 데이터를 먼저 직접 확인하는 습관이 가장 중요하다는 것을 배웠습니다.