영화 대사 코퍼스 기반 텍스트 분류 모델 성능 비교 및 분석

CANLAS NICOLE (2555039)

1. 데이터 준비

본 과제에서는 모델 학습에 앞서 제공된 CSV 파일의 라벨과 출처를 먼저 점검하였다. 그 결과 계획서와 다른 점 세 가지를 확인하였다. 첫째, DARTH VADER 대사가 0행이었다(Cornell 코퍼스의 표기명은 `VADER`). 둘째, 다른 영화의 동명 캐릭터 대사(『Dune』 의 EMPEROR 등)가 섞여 있었다. 셋째, "1000lines" 파일은 실제로 552행이었다. 이에 Cornell 원본에서 영화 ID로 스타워즈 3부작만 다시 추출하고 중복·라벨 충돌 대사를 제거하였다. 네 캐릭터의 스타워즈 대사는 약 490행뿐이어서 1,000행 구성은 불가능하였다.

데이터셋	LUKE	LEIA	VADER	EMPEROR	합계	Bad 비율
Small (Part 1)	94	–	25	6	125	24.8%
Large (Part 2)	229	175	62	14	480	15.8%
제공 Large (비교용)	340	174	0	23	537	4.3%

모든 실험은 동일한 반복 층화 5-Fold(25개 폴드)로 평가하였으며, 데이터 누출을 방지하기 위해 벡터라이저와 분류기를 Pipeline으로 묶어 훈련 폴드에서만 학습하였다.

2. 결과표

아래 수치는 25개 폴드의 평균이며, Macro-F1은 평균 ± 표준편차로 표기하였다.

데이터	벡터화	모델	불균형	Acc	Bad P	Bad R	Bad F1	Macro-F1
Small	TF-IDF	LogReg	balanced	0.813	0.660	0.567	0.593	0.735 ± 0.107
Small	SBERT	LogReg	balanced	0.858	0.735	0.708	0.710	0.807 ± 0.088
Large	TF-IDF	LinearSVC	balanced	0.890	0.716	0.537	0.605	0.771 ± 0.035
Large	TF-IDF	LogReg	balanced	0.876	0.622	0.587	0.599	0.763 ± 0.040
Large	SBERT	LogReg	balanced	0.847	0.522	0.722	0.599	0.752 ± 0.046
Large	Count	MultinomialNB	none	0.896	0.826	0.437	0.560	0.751 ± 0.070
Large	Count	GradBoost	balanced	0.856	0.588	0.507	0.528	0.721 ± 0.064
Large	Count	RandomForest	none	0.870	0.888	0.198	0.315	0.622 ± 0.074

3. 연구 질문에 대한 답

Q1. 데이터 규모: 데이터를 늘리자 20개 설정 중 19개에서 Macro-F1이 상승하고 19개에서 표준편차가 감소하였다(최종 모델 0.107 → 0.040). 반면 Bad Recall은 0.567 → 0.587로 거의 변하지 않았다.

Q2. Accuracy vs Bad Recall: Large에서 Accuracy가 가장 높은 Count + NB(0.896)는 Bad Recall이 0.437에 그쳤다. 가중치를 적용하지 않은 TF-IDF LR은 Accuracy 0.842를 기록했으나 거의 모든 대사를 Good으로 예측하였다(Bad Recall 0.003).

Q3. Count vs TF-IDF: 선형 모델(balanced)에서는 TF-IDF가 Macro-F1을 0.03–0.05 높였고, NB·RF에서는 Count가 우수하였다. 대사가 짧아(중앙값 6단어) 빈도가 대부분 0/1이므로 IDF보다 L2 정규화의 영향이 컸던 것으로 판단된다.

Q4. 최종 모델: TF-IDF + 로지스틱 회귀(balanced)를 최종 모델로 선정하였다. Small 1위(0.735), Large 2위(0.763)로 두 규모 모두에서 상위였으며, Bad Precision·Recall이 모두 0.5 이상이었다.

Q5. 사전학습 임베딩: 동일한 폴드로 실행한 SBERT(all-MiniLM-L6-v2) + LR(balanced)은 Small에서 Macro-F1 0.807로 TF-IDF(0.735)보다 높았고, Large에서는 Bad Recall이 높았으나(0.722 vs 0.587) Precision이 낮아(0.522) Macro-F1은 비슷하였다(0.752). 인코딩이 문장당 약 12 ms로 저렴하여 소규모 데이터에서 활용 가치가 있다고 판단하였다.

4. 오분류 사례

최종 모델(Large)은 Bad 76개 중 33개를 놓쳤고, Good 24개를 Bad로 오분류하였다. 모델이 화자의 성격보다 주제어와 명령조 문체(관사 "the")를 학습한 것으로 분석된다.

실제 → 예측	화자: 대사	원인 (기여 단어)
Bad → Good	VADER: What is thy bidding, My Master?	what(+0.28)이 Bad 단서 상쇄
Good → Bad	LUKE: Lord Vader … Is the dark side stronger?	악역 주제어 dark side(−0.23)
Good → Bad	LEIA: Yes.	Vader 대사 탓에 yes(−0.74)

5. 한계와 배운 점

- **한계 및 개선:** Bad 표본이 76개뿐이라 상위 모델 간 차이가 통계적으로 구분되지 않는다. 향후 중첩 교차검증과 악역 캐릭터 추가로 보완하고자 한다.
- **배운 점:** 첫째, 모델링보다 데이터 검증이 우선이다. 라벨 누락과 출처 오류를 놓쳤다면 모든 결과가 무의미했을 것이다. 둘째, 불균형 데이터에서는 Accuracy보다 소수 클래스의 Recall과 혼동행렬을 봐야 한다. 셋째, 표본이 적을수록 반복 교차검증으로 안정성을 확인해야 한다.