# 인공지능모델운영 과제 보고서

**주제:** CV & Optuna 하이퍼파라미터 튜닝 | **이름:** CANLAS NICOLE | **학번:** 2555039

## 1. 전처리 및 방법론 (Methodology)

- **정제:** Name에서 Title(Mr, Miss, Mrs, Master, Rare)을 추출하고 PassengerId, Ticket, Cabin, Name을 제거함.
- **결측치·변환:** Age는 GroupMedianImputer(Pclass×Title 중앙값), Embarked는 최빈값으로 대체하고, 수치형은 StandardScaler, 범주형은 OneHotEncoder(drop='first')를 적용함.
- **누수 차단:** 전처리 전체를 Pipeline 내부에 두어 학습 Fold에서만 fit하고, StratifiedKFold(5, shuffle=True, random_state=42)로 평가함. FN+FP는 Fold당 평균 오분류 건수임.

## 2. Baseline 5-Fold 성능 평가

| Model | FN+FP | FPR | Recall | Precision | F1-Score | PR_AUC | AUROC |
|---|---|---|---|---|---|---|---|
| KNN | 32.2 | 0.1294 | 0.7368 | 0.7829 | 0.7581 | 0.7753 | 0.8538 |
| Logistic Regression | **31.2** | **0.1202** | 0.7366 | **0.7934** | **0.7631** | 0.8489 | 0.8702 |
| Naive Bayes | 38.6 | 0.1585 | 0.6898 | 0.7309 | 0.7087 | 0.7654 | 0.8376 |
| Decision Tree | 36.6 | 0.1621 | 0.7251 | 0.7358 | 0.7303 | 0.6388 | 0.7788 |
| Random Forest | 32.4 | 0.1311 | 0.7368 | 0.7785 | 0.7568 | 0.8237 | 0.8708 |
| XGBoost | 32.0 | 0.1293 | **0.7396** | 0.7808 | 0.7596 | **0.8495** | **0.8738** |

Logistic Regression이 오분류 수·F1에서, XGBoost가 AUROC에서 우수함. 깊이 제한이 없는 Decision Tree는 과적합으로 PR_AUC(0.6388)가 최하위임.

## 3. Optuna 하이퍼파라미터 튜닝 결과

TPE Sampler(seed=42), 모델당 50 trials, 평균 5-Fold F1 최대화 (괄호 = Best CV F1).

- **XGBoost (0.7957):** n_estimators=100, max_depth=8, learning_rate=0.0649, subsample=0.823, colsample_bytree=0.765, min_child_weight=2, gamma=0.157
- **Random Forest (0.7853):** n_estimators=300, max_depth=15, min_samples_split=2, min_samples_leaf=2, max_features='log2'

- **Logistic Regression (0.7767):** C=6.847, penalty='l2' / **Decision Tree (0.7710):** criterion='gini', max_depth=3, min_samples_split=15, min_samples_leaf=5
- **KNN (0.7662):** n_neighbors=17, weights='uniform', p=1 / **Naive Bayes (0.7087):** var_smoothing=1.77e-09

## 4. Tuned 5-Fold 최종 성능 평가

| Model (Tuned) | FN+FP | FPR | Recall | Precision | F1-Score | PR_AUC | AUROC |
|---|---|---|---|---|---|---|---|
| KNN | 30.6 | 0.1129 | 0.7338 | 0.8021 | 0.7662 | 0.8413 | 0.8751 |
| Logistic Regression | 29.6 | 0.1166 | 0.7542 | 0.8015 | 0.7767 | 0.8549 | 0.8731 |
| Naive Bayes | 38.6 | 0.1585 | 0.6898 | 0.7309 | 0.7087 | 0.7654 | 0.8376 |
| Decision Tree | 30.4 | 0.1221 | 0.7512 | 0.7935 | 0.7710 | 0.8102 | 0.8629 |
| Random Forest | 28.0 | 0.0984 | 0.7485 | 0.8273 | 0.7853 | 0.8560 | 0.8787 |
| XGBoost | **26.8** | **0.0965** | **0.7631** | **0.8317** | **0.7957** | **0.8619** | **0.8812** |

XGBoost (Tuned)가 7개 지표 모두 1위임. 오분류 수는 Decision Tree −6.2, XGBoost −5.2, Random Forest −4.4, KNN·Logistic Regression −1.6건 감소하였고, 개선은 주로 FPR 하락 (XGBoost 0.1293→0.0965)에서 비롯됨.

## 5. 결론 및 종합 고찰

- **XGBoost 우위:** 잔차 순차 보정으로 변수 간 상호작용을 포착하고, 깊이(8)를 낮은 학습률·표본추출·gamma로 규제하여 편향–분산 균형을 확보함.
- **모델별 차이:** Decision Tree는 max_depth=3 사전 가지치기로 과적합이 해소되어 PR_AUC +0.1714를 기록함. Naive Bayes는 var_smoothing이 구조를 바꾸지 못해 변화가 없으며, 한계는 조건부 독립 가정에 있음.
- **Pipeline 이점:** Fold마다 clone(pipeline).fit()으로 전처리 통계량을 학습 Fold에서만 산출하여 데이터 누수를 차단함.
- **한계:** 튜닝·평가에 동일 Fold를 사용해 낙관적 편향이 있으므로 Nested CV 검증이 필요함.